

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РФ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НОВОСИБИРСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

Кафедра автоматизированных систем управления



ОТЧЁТ
по РАСЧЕТНО-ГРАФИЧЕСКОЙ РАБОТЕ
по дисциплине: «*Теория случайных процессов*»

Выполнил:

Студент гр. АП-226, АВТФ
Лужков Николай Дмитриевич

«___» ____ 20__ г.

(подпись)

Проверил:

к.т.н., доцент АСУ
Ганелина Наталья
Давидовна

«___» ____ 20__ г.

(подпись)

Новосибирск 2025

Цель работы

Изучить методологию анализа временного ряда.

Задание

Для выбранного временного ряда провести визуальный анализ, оценить наличие выбросов с помощью критерия, построить коррелограммы, обосновать выбор моделей (не менее двух, например, модели одно-, двух-, трехпараметрического экспоненциального сглаживания, ARMA, ARIMA). Описать результаты прогнозирования с помощью моделей (не менее трех метрик, например, MAE, MSE, MAPE), построить и проанализировать коррелограмму и графики остатков. Обосновать выбор параметров моделей. Исследовать влияние параметров на качество модели.

Описание временного ряда и визуальный анализ

В качестве входных данных обратимся к статистике обращений в банк Х на территории Российской Федерации с запросом о выдаче кредита с 01 июля 2019 года по 21 мая 2025 года.

Таблица 1 – Исходные данные

Week	Amount
31.12.2018	130228
07.01.2019	196906
14.01.2019	216984
21.01.2019	230502
28.01.2019	223810
04.02.2019	229025
11.02.2019	208763
18.02.2019	217541
25.02.2019	217951
04.03.2019	213543
11.03.2019	262002
18.03.2019	267062
25.03.2019	264999
01.04.2019	259801
08.04.2019	246232
15.04.2019	218707
22.04.2019	196594
29.04.2019	155103
06.05.2019	147557
13.05.2019	178498
20.05.2019	176563
27.05.2019	163765
03.06.2019	168799

10.06.2019	160991
17.06.2019	167740
24.06.2019	166857
01.07.2019	168341
08.07.2019	173899
15.07.2019	177298
22.07.2019	174254
29.07.2019	172306
05.08.2019	177369
12.08.2019	168987
19.08.2019	173396
26.08.2019	173516
02.09.2019	166066
09.09.2019	165877
16.09.2019	171271
23.09.2019	183679
30.09.2019	192750
07.10.2019	188083
14.10.2019	175567
21.10.2019	182097
28.10.2019	183370
04.11.2019	175767
11.11.2019	186064
18.11.2019	183160
25.11.2019	198198
02.12.2019	198896
09.12.2019	213201
16.12.2019	223276
23.12.2019	210425

30.12.2019	132814
06.01.2020	198973
13.01.2020	213349
20.01.2020	207952
27.01.2020	189058
03.02.2020	215133
10.02.2020	194753
17.02.2020	186381
24.02.2020	193229
02.03.2020	183683
09.03.2020	212203
16.03.2020	221466
23.03.2020	192687
30.03.2020	193839
06.04.2020	179892
13.04.2020	182846
20.04.2020	188772
27.04.2020	180116
04.05.2020	158731
11.05.2020	176317
18.05.2020	186721
25.05.2020	182700
01.06.2020	188348
08.06.2020	179646
15.06.2020	202363
22.06.2020	189690
29.06.2020	169887
06.07.2020	174078
13.07.2020	173637

20.07.2020	169639
27.07.2020	165467
03.08.2020	164099
10.08.2020	172348
17.08.2020	175291
24.08.2020	165732
31.08.2020	163280
07.09.2020	165219
14.09.2020	163714
21.09.2020	182558
28.09.2020	186901
05.10.2020	202277
12.10.2020	209906
19.10.2020	207831
26.10.2020	212442
02.11.2020	238263
09.11.2020	230543
16.11.2020	254155
23.11.2020	254765
30.11.2020	235993
07.12.2020	228393
14.12.2020	224740
21.12.2020	212942
28.12.2020	145015
04.01.2021	178455
11.01.2021	244131
18.01.2021	230770
25.01.2021	230431
01.02.2021	232147

08.02.2021	223567
15.02.2021	224771
22.02.2021	222483
01.03.2021	230651
08.03.2021	250496
15.03.2021	241919
22.03.2021	248774
29.03.2021	249119
05.04.2021	257078
12.04.2021	270478
19.04.2021	278303
26.04.2021	229796
03.05.2021	200933
10.05.2021	300760
17.05.2021	304058
24.05.2021	228204
31.05.2021	270166
07.06.2021	222620
14.06.2021	197524
21.06.2021	188939
28.06.2021	213289
05.07.2021	222977
12.07.2021	235157
19.07.2021	222096
26.07.2021	212165
02.08.2021	199167
09.08.2021	202435
16.08.2021	222222
23.08.2021	223834

30.08.2021	209765
06.09.2021	202379
13.09.2021	208212
20.09.2021	203372
27.09.2021	189870
04.10.2021	196997
11.10.2021	193301
18.10.2021	193854
25.10.2021	203536
01.11.2021	197635
08.11.2021	213752
15.11.2021	259140
22.11.2021	219806
29.11.2021	201444
06.12.2021	201126
13.12.2021	198545
20.12.2021	179812
27.12.2021	127883
03.01.2022	138342
10.01.2022	178943
17.01.2022	183083
24.01.2022	188535
31.01.2022	204432
07.02.2022	197965
14.02.2022	195648
21.02.2022	191097
28.02.2022	211551
07.03.2022	173898
14.03.2022	181628

21.03.2022	181852
28.03.2022	190226
04.04.2022	184485
11.04.2022	189806
18.04.2022	198255
25.04.2022	191874
02.05.2022	174919
09.05.2022	183029
16.05.2022	210801
23.05.2022	224980
30.05.2022	216969
06.06.2022	209214
13.06.2022	220369
20.06.2022	194046
27.06.2022	187165
04.07.2022	177543
11.07.2022	182988
18.07.2022	182296
25.07.2022	177708
01.08.2022	192433
08.08.2022	187589
15.08.2022	186141
22.08.2022	176599
29.08.2022	166258
05.09.2022	159201
12.09.2022	152959
19.09.2022	140471
26.09.2022	132984
03.10.2022	134774

10.10.2022	130913
17.10.2022	141407
24.10.2022	135717
31.10.2022	134492
07.11.2022	132978
14.11.2022	134176
21.11.2022	129971
28.11.2022	129263
05.12.2022	136544
12.12.2022	137006
19.12.2022	126277
26.12.2022	91514
02.01.2023	91486
09.01.2023	122882
16.01.2023	122993
23.01.2023	126400
30.01.2023	128507
06.02.2023	128662
13.02.2023	127639
20.02.2023	117463
27.02.2023	125267
06.03.2023	118836
13.03.2023	129249
20.03.2023	122076
27.03.2023	121076
03.04.2023	114497
10.04.2023	108328
17.04.2023	109746
24.04.2023	106531

01.05.2023	99560
08.05.2023	99724
15.05.2023	107543
22.05.2023	102973
29.05.2023	100637
05.06.2023	101242
12.06.2023	103539
19.06.2023	104470
26.06.2023	103908
03.07.2023	93447
10.07.2023	99526
17.07.2023	99833
24.07.2023	107289
31.07.2023	97341
07.08.2023	102509
14.08.2023	114591
21.08.2023	110625
28.08.2023	94150
04.09.2023	96099
11.09.2023	96528
18.09.2023	96862
25.09.2023	101167
02.10.2023	96753
09.10.2023	93729
16.10.2023	93826
23.10.2023	95279
30.10.2023	91680
06.11.2023	91991
13.11.2023	97693

20.11.2023	95657
27.11.2023	96968
04.12.2023	98359
11.12.2023	93891
18.12.2023	91109
25.12.2023	74900
01.01.2024	66742
08.01.2024	95910
15.01.2024	99101
22.01.2024	99617
29.01.2024	97402
05.02.2024	95368
12.02.2024	96501
19.02.2024	87828
26.02.2024	97588
04.03.2024	87060
11.03.2024	87612
18.03.2024	90282
25.03.2024	88496
01.04.2024	85487
08.04.2024	86249
15.04.2024	90682
22.04.2024	89167
29.04.2024	79308
06.05.2024	80183
13.05.2024	93797
20.05.2024	88343
27.05.2024	91727
03.06.2024	90542

10.06.2024	85484
17.06.2024	89415
24.06.2024	83374
01.07.2024	84031
08.07.2024	87459
15.07.2024	96257
22.07.2024	93043
29.07.2024	86244
05.08.2024	81363
12.08.2024	80466
19.08.2024	81918
26.08.2024	82662
02.09.2024	71076
09.09.2024	73703
16.09.2024	75955
23.09.2024	77818
30.09.2024	80256
07.10.2024	85595
14.10.2024	96930
21.10.2024	106932
28.10.2024	109118
04.11.2024	92351
11.11.2024	105201
18.11.2024	93052
25.11.2024	100282
02.12.2024	89042
09.12.2024	93124
16.12.2024	98973
23.12.2024	96331

30.12.2024	68323
06.01.2025	90386
13.01.2025	93276
20.01.2025	93660
27.01.2025	93470
03.02.2025	91554
10.02.2025	94241
17.02.2025	95118
24.02.2025	93141
03.03.2025	90622
10.03.2025	105831
17.03.2025	101596
24.03.2025	96279
31.03.2025	106313
07.04.2025	91523
14.04.2025	119639
21.04.2025	99346
28.04.2025	97586
05.05.2025	87595
12.05.2025	117899

На рисунке 1 представлен график исходных данных. Можно определить, что присутствует смена тренда с восходящего на нисходящий, вероятно, можно наблюдать сезонность в период новогодних праздников, при этом дисперсия непостоянна (Прим.: вероятно, процесс стабилизируется в отношении внешних факторов).



Рисунок 1 – График исходных данных

На рисунке 2 представлен график автокорреляционной функции. Его постепенное «медленное» убывание доказывает наличие тренда. Лаги заданы в неделях, т.к. исходные данные также заданы в неделях. В областях лагов, кратных 12, можно проследить связь с исходными данными, что потенциально доказывает сезонность.

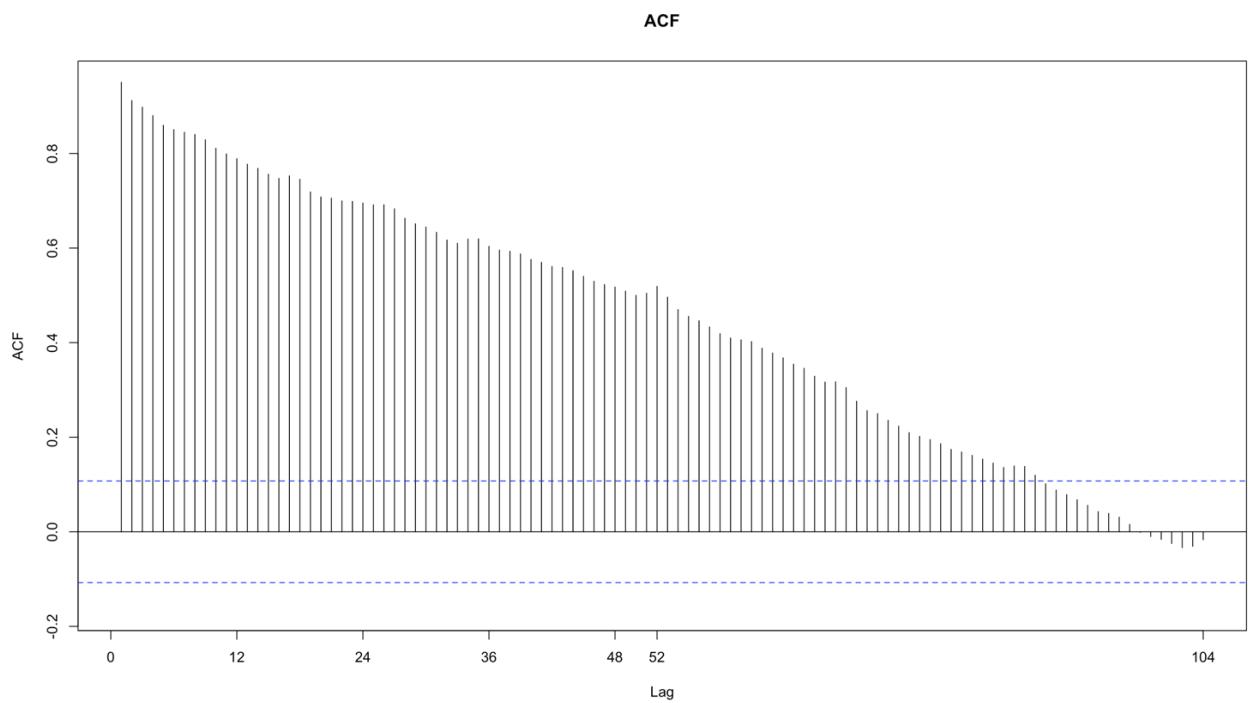


Рисунок 2 – График автокорреляционной функции

Далее, обратимся к частной автокорреляционной функции. Ее график представлен на рисунке 3. На графике виден доминирующий пик при лаге 1, что является признаком AR(1) – процесса. Однако, есть также выходы за доверительный интервал при лагах 3, 17, 19. Последние два, вероятно, являются шумом, а лаг 3 проверим в дальнейшем.

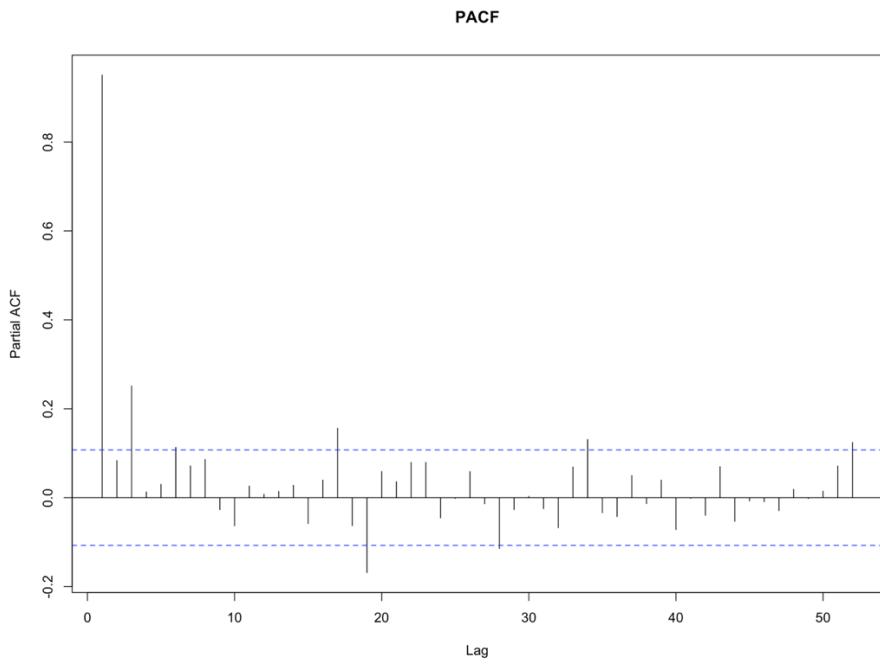


Рисунок 3 – График частной автокорреляционной функции

Далее, удалим тренд из исходных данных и получим график, представленный на рисунке 4.

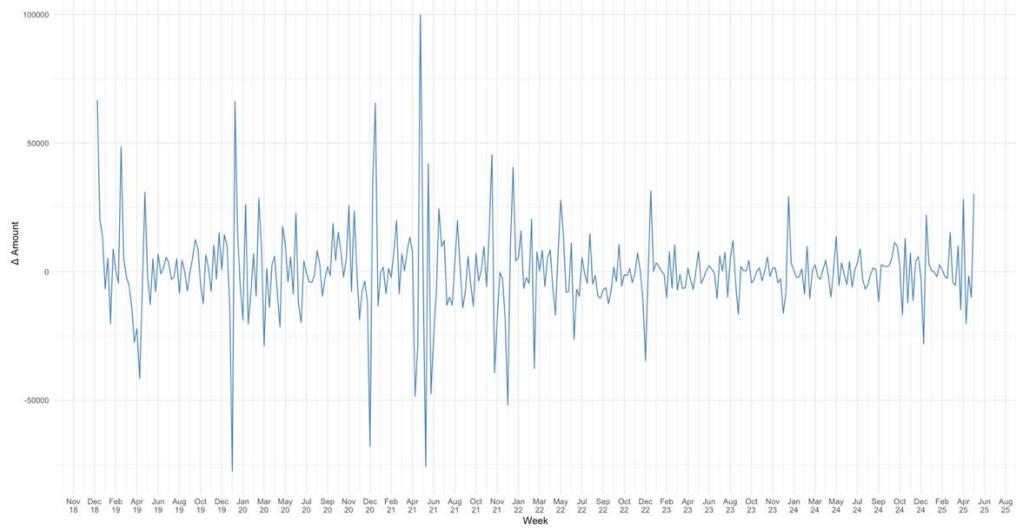


Рисунок 4 – График исходных данных без тренда

Далее, проанализируем выбросы. Для этого используем метод межквартильного размаха. Метод заключается в расчете первого и третьего квартилей, затем рассчитываем интерквартильный размах, и с его помощью определяем границы. Значения, которые выходят за эти границы, будем

считать выбросами. Фрагмент кода для расчета выбросов представлен на рисунке 5.

```
1 Q1 <- quantile(amount_diff, 0.25)
2 Q3 <- quantile(amount_diff, 0.75)
3 IQR_val <- Q3 - Q1
4 lower_bound <- Q1 - 1.5 * IQR_val
5 upper_bound <- Q3 + 1.5 * IQR_val
6 outliers <- which(amount_diff < lower_bound | amount_diff > upper_bound)
7
```

Рисунок 5 – Поиск выбросов

Удобно визуально представить либо свечным графиком, либо так, как представлено на рисунках 6.1 и 6.2.

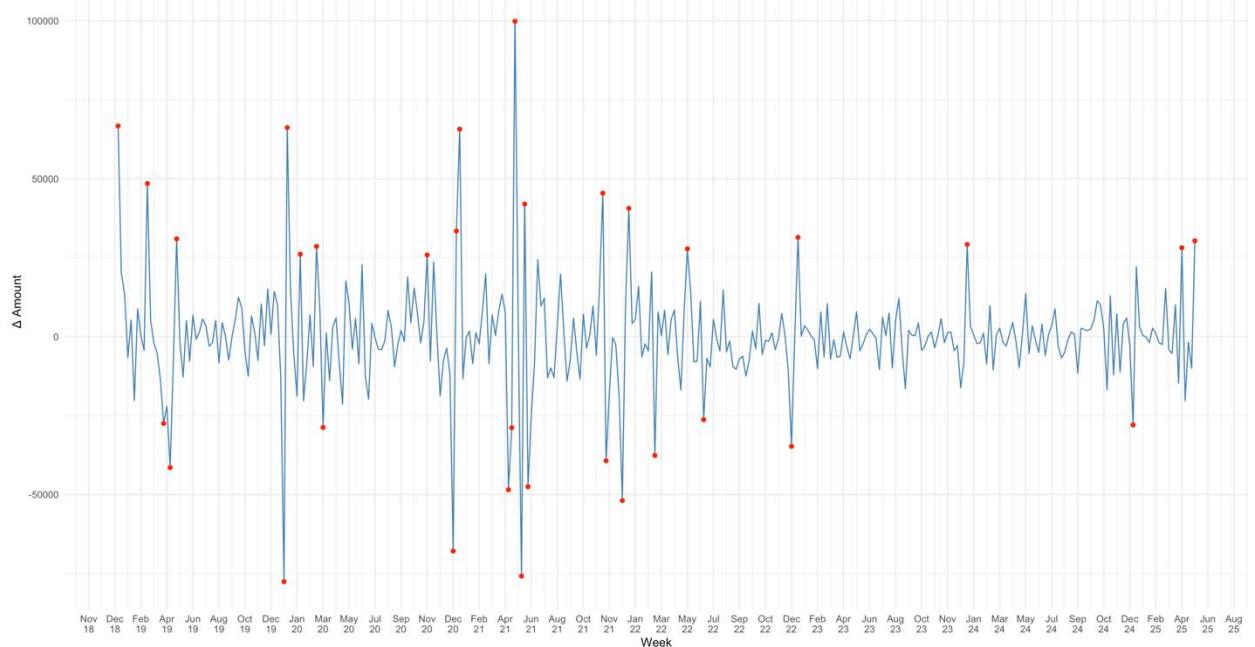


Рисунок 6.1 – Выбросы в исходных данных (с удаленным трендом)

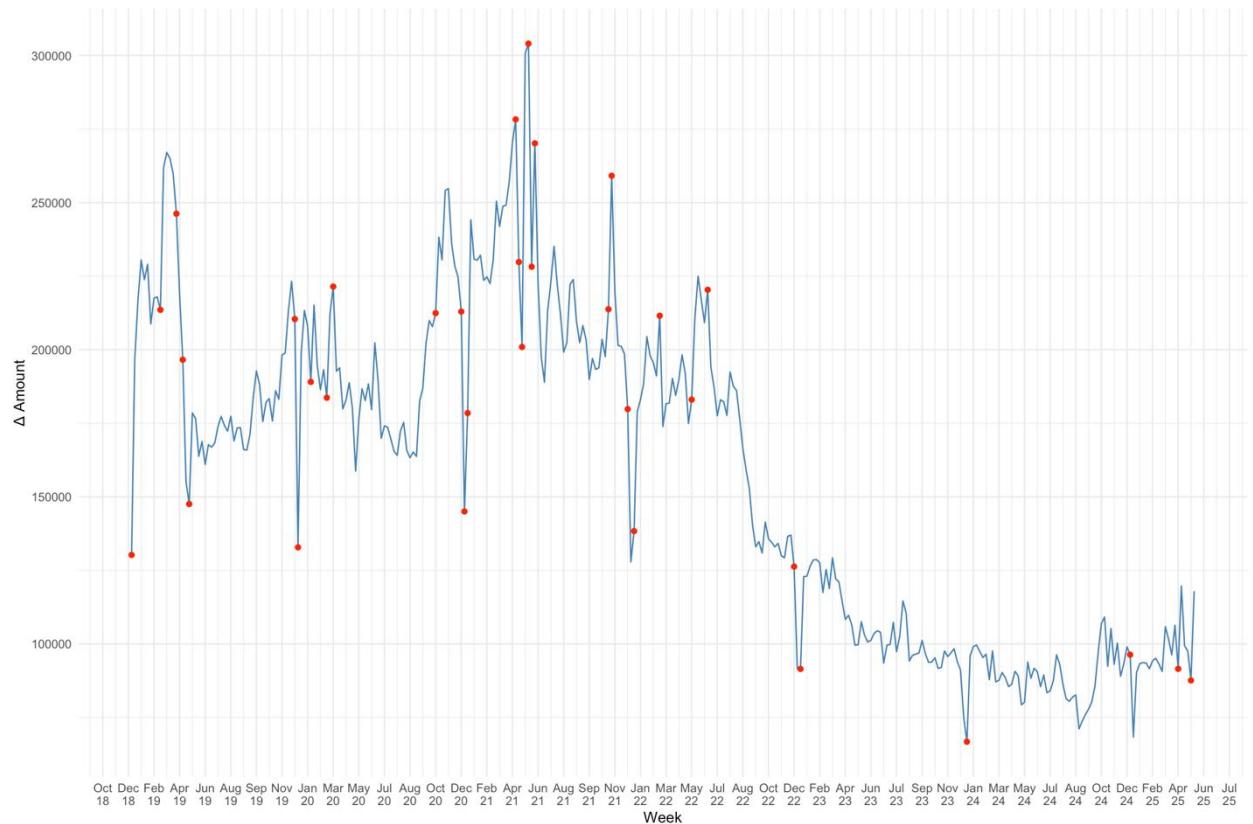


Рисунок 6.2 – Выбросы в исходных данных

Устраним их и получим график, представленный на рисунке 7.

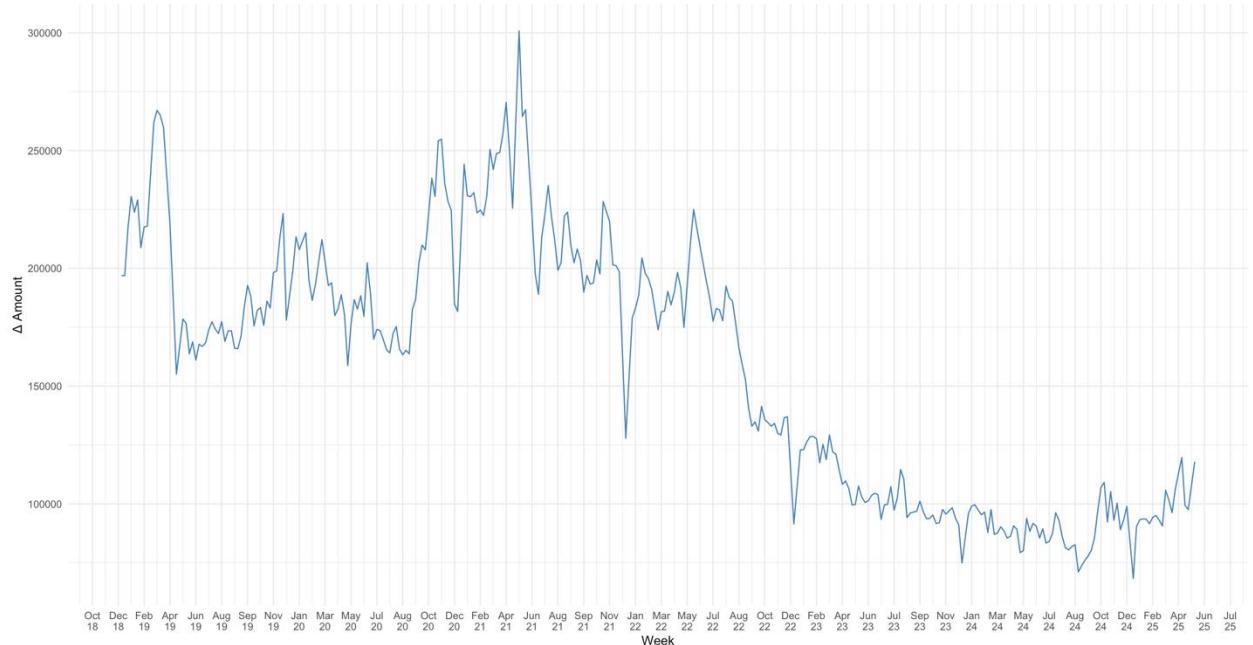


Рисунок 7 – График без выбросов

Так как есть тренд и, вероятно, сезонность, то будем использовать

модель SARIMA, а также трехпараметрическое экспоненциальное сглаживание.

Модель SARIMA

Влияние параметров модели на эффективность алгоритма

Для подбора параметров SARIMA использовалась функция Arima() из библиотеки forecast в R. Было протестировано 10 моделей с различными наборами параметров (p, d, q) и (P, D, Q). Оценка качества производилась по метрикам RMSE (среднеквадратическая ошибка), MAE (средняя абсолютная ошибка) и MAPE (средняя абсолютная процентная ошибка). Также применялся тест Люнга-Бокса (p-value), позволяющий оценить автокоррелированность остатков модели.

Если $p - value > 0.05$, остатки ведут себя как белый шум — модель адекватна. Если < 0.05 — остатки всё ещё автокоррелированы, модель недостаточно точна.

Таблица 2 – Расчет метрик для моделей с различными параметрами

№ модели	p	d	q	P	D	Q	RMSE	MAE	MAPE	p-value
1	1	1	0	0	1	0	30859.48	24646.91	25.6	1e-04
2	1	1	1	0	1	0	30675.82	24478.43	25.42	7e-04
3	3	1	0	0	1	0	29520.6	23429.09	24.29	0.0175
4	3	1	1	0	1	0	29619.39	23520.83	24.39	0.0121
5	1	1	0	1	1	0	-	-	-	-
6	1	1	1	1	1	0	-	-	-	-
7	3	1	0	1	1	0	43415.33	33533.79	34.98	0.3085
8	3	1	1	1	1	0	43547.21	33678.4	35.14	0.263
9	1	1	0	0	1	1	30267.95	25912.47	27.55	0.2745
10	1	1	1	0	1	1	29843.31	25512.89	27.11	0.364

Модели №5 и №6 не сошлись — при обучении возникли численные ошибки, связанные с избыточной сложностью модели или некорректной комбинацией параметров.

Из рассмотренных в таблице 2 моделей наилучшей по совокупности критериев RMSE, MAE, MAPE и p-value является модель SARIMA(3,1,0)(0,1,0) (модель №3). Она обеспечивает наименьшие значения ошибок ($RMSE = 29520.6$, $MAE = 23429.09$) при $p\text{-value} = 0.0175$, что указывает на отсутствие автокорреляции остатков.

Также стоит отметить модель №4 (SARIMA(3,1,1)(0,1,0)), которая имела схожие значения ошибок и $p\text{-value} = 0.0121$.

Модели №7 и №8, несмотря на высокий $p\text{-value}$, показали крайне высокие ошибки прогноза — более 43 тыс. по RMSE и MAPE выше 34%, что делает их непригодными для использования.

Таким образом, модель №3 выбираем в качестве основной модели, но также дополнительно рассмотрим модель №4.

Результаты моделирования

Для обучающей выборки было отложено 79% исходных данных (266 недель), остальные данные (67 недель) использовались для оценки качества прогноза. Графики полученных рядов для моделей № 3, 4 представлены на рисунках 8 и 9.

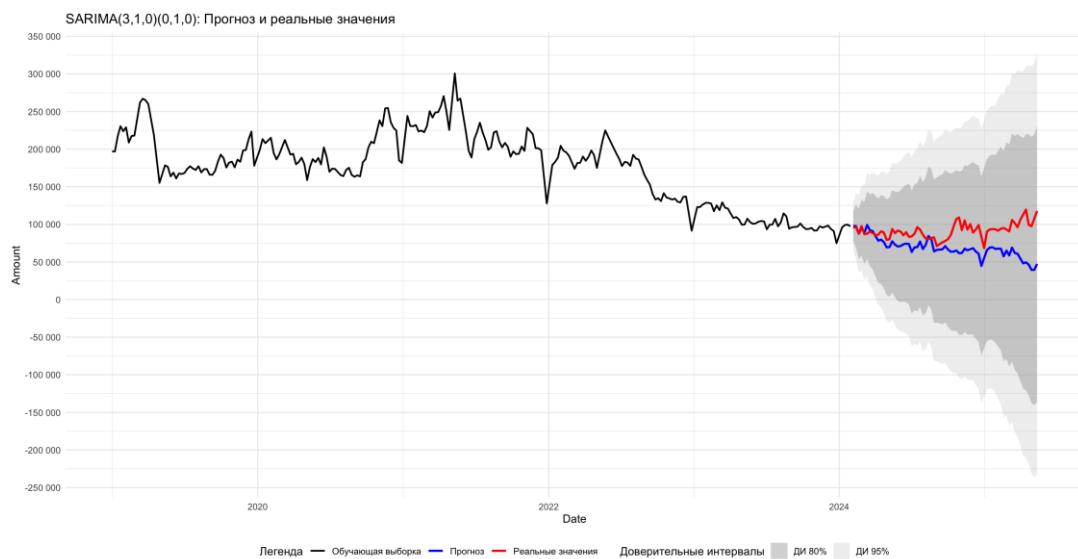


Рисунок 8 – График для модели №3

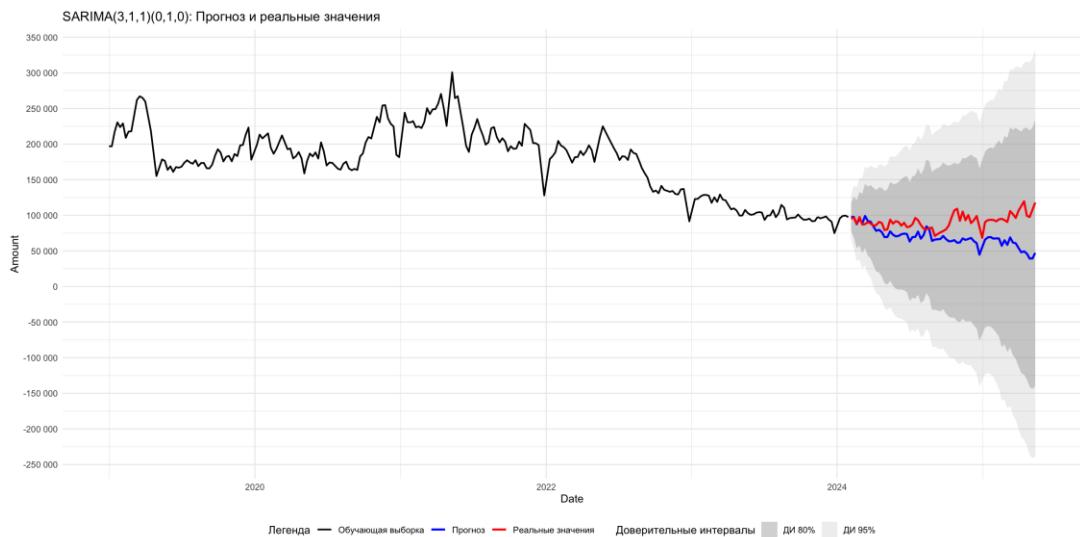


Рисунок 9 – График для модели №4

Визуально прогнозы по разным моделям не отличаются, но так как у модели №3 меньшие значения ошибок, в дальнейшем будем использовать ее.

Анализ остатков

По рисунку 10, на котором представлен график остатков для прогноза по модели SARIMA №3, и рисунку 11, на котором представлена коррелограмма остатков, можно сделать вывод, что остатки модели в целом распределены симметрично относительно нуля, что указывает на несмещённость модели.

Однако на коррелограмме видны отдельные пики, выходящие за границы доверительных интервалов, что может свидетельствовать о наличии остаточной автокорреляции.

Для подтверждения выводов проведены статистические тесты:

Таблица №3 – Тесты для остатков модели №3

Тест	Результаты
KPSS test	KPSS Level = 0.045272, Truncation lag parameter = 5, p-value = 0.1
Box-Ljung test	X-squared = 171.64, df = 52, p-value = 1.055e-14

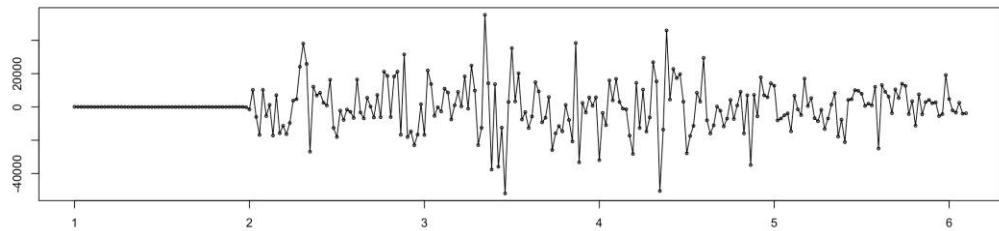


Рисунок 10 – График остатков для модели №3

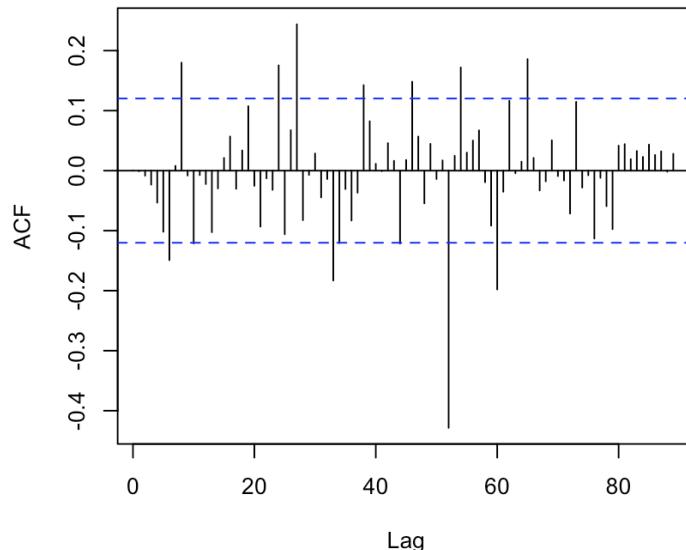


Рисунок 11 – Кореллограмма остатков для модели №4

Несмотря на визуальную приемлемость остатков и то, что они в целом распределены вокруг нуля, результаты теста Льюнга–Бокса показали $p\text{-value} < 0.05$. Это говорит о наличии автокорреляции в остатках, что означает неполную адекватность моделей. Тем не менее, визуально модели удовлетворительно воспроизводят поведение ряда и дают интерпретируемые прогнозы. Такая ситуация может быть связана с наличием сложной, возможно меняющейся во времени сезонной структуры или влиянием дополнительных факторов, не учтённых в модели.

Оценка качества прогноза

В результате сравнения имеющихся данных и прогноза на 67 недель были получены следующие значения ошибок: MAPE = 24.29 %, MAE = 23 429, RMSE = 29 521.

Наиболее показательной является ошибка MAPE. Считаем модель приемлемой, если MAPE меньше 10%. Но в результате вычислений, программа получила 24.29%, что является удовлетворительным результатом.

Спрогнозируем значения ряда на 13 недель вперед, результаты прогноза представлены на рисунке 12.



Рисунок 12 – Прогноз на ближайшие 3 месяца

Трехпараметрическое экспоненциальное сглаживание

Влияние параметров модели на эффективность алгоритма

Прежде чем выбрать конкретные значения параметров модели, рассмотрим разные варианты аналогично модели SARIMA.

Таблица 4 – Расчет метрик для моделей с различными параметрами

№ модели	alpha	beta	gamma	RMSE	MAE	MAPE
1	auto(0.989)	auto(N/A)	auto(N/A)	11179	8160	8.68
2	0.2	0.1	0.2	109621	98697	106.46
3	0.4	0.2	0.3	135851	122929	132.53
4	0.6	0.2	0.4	107041	97246	104.72
5	0.8	0.4	0.2	86713	78134	83.89
6	0.3	0.3	0.3	170484	152831	164.73

Модель 1, построенная с использованием встроенной в R функции, автоматически подбирающей параметры, продемонстрировала наилучшие показатели качества прогноза с минимальными значениями RMSE = 11179, MAE = 8160 и MAPE = 8,68. Это свидетельствует о том, что модель с параметрами $\alpha = 0.989$, $\beta = 0$, $\gamma = 0$ наиболее точно прогнозирует временной ряд.

Таким образом, модель №1 выбрана для окончательного прогнозирования.

Результаты моделирования

Для обучающей выборки было отложено 79% исходных данных (266 недель), остальные данные (67 недель) использовались для оценки качества прогноза. График полученного ряда представлен на рисунке 13.

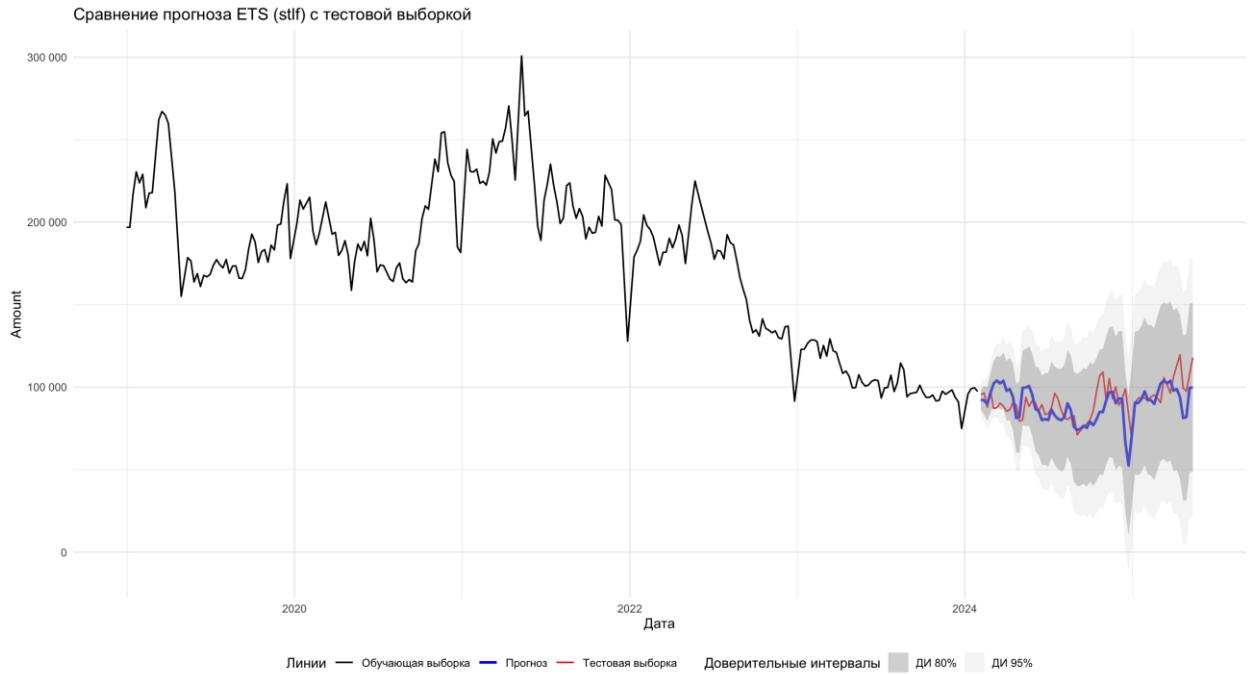


Рисунок 13 – График для выбранной модели

Анализ остатков

По рисунку 14, на котором представлен график остатков для прогноза по модели и коррелограмма остатков, можно сделать вывод, что остатки модели в целом распределены симметрично относительно нуля, что указывает на несмещённость модели.

Однако на коррелограмме видны отдельные пики (Прим.: меньшее количество, чем в модели SARIMA), выходящие за границы доверительных интервалов, что может свидетельствовать о наличии остаточной автокорреляции.

Для подтверждения выводов проведены статистические тесты:

Таблица №5 – Тесты для остатков модели

Тест	Результаты
KPSS test	KPSS Level = 0.084402, Truncation lag parameter = 5, p-value = 0.1
Box-Ljung test	X-squared = 108.9, df = 52, p-value = 6.569e-06

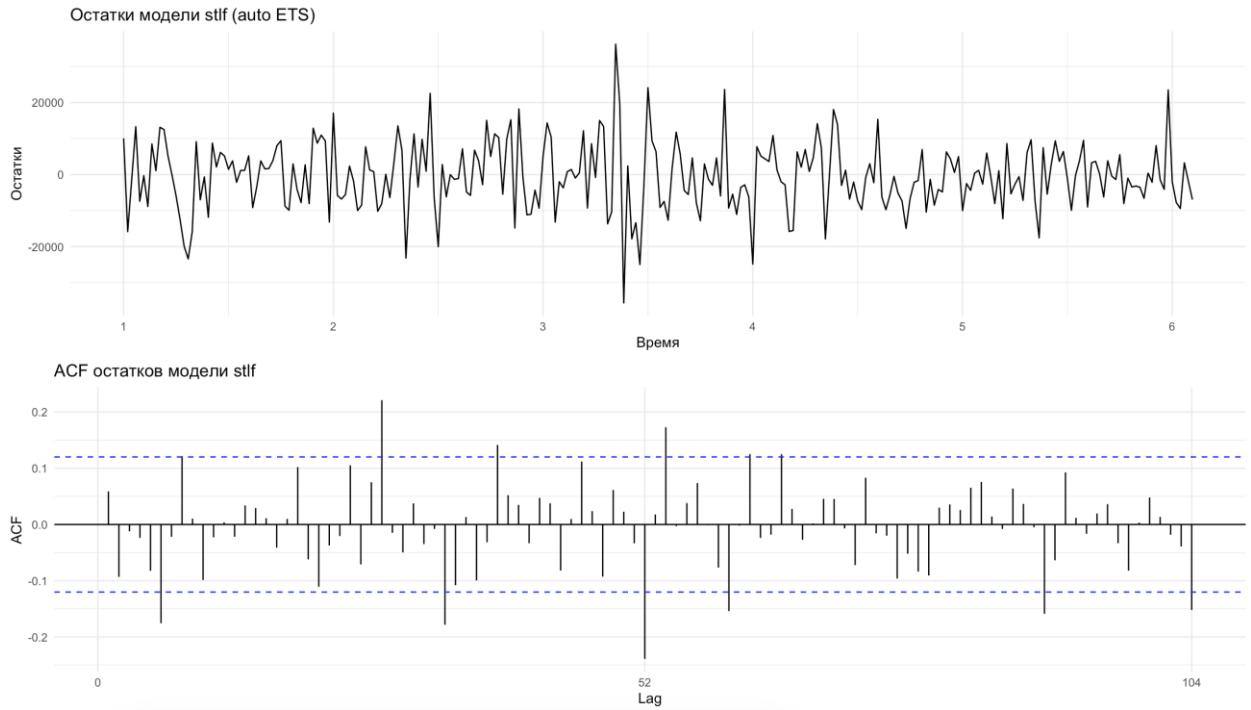


Рисунок 14 – График и кореллограмма остатков

Модель обеспечивает качественный прогноз ($MAPE < 10\%$), однако остатки обладают автокорреляцией, что указывает на неполное объяснение внутренней структуры временного ряда. Это ограничивает интерпретируемость модели, несмотря на хорошие метрики точности.

Оценка качества прогноза

В результате сравнения имеющихся данных и прогноза на 67 недель были получены следующие значения ошибок: $MAPE = 8.68 \%$, $MAE = 8\ 160.39$, $RMSE = 11\ 178.78$.

Спрогнозируем значения ряда на 3 месяца вперед по выбранной модели. Однако, учитывая автокоррелированность остатков, этот прогноз нельзя считать полностью адекватным. Результаты представлены на рисунке 15.

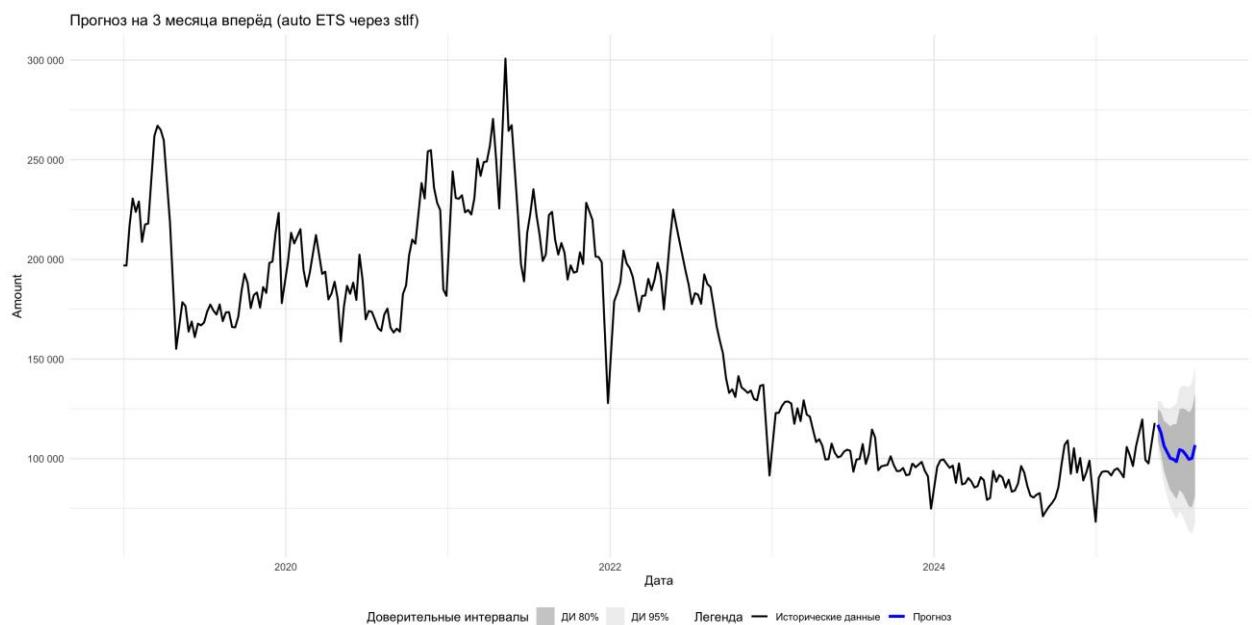


Рисунок 15 – Прогноз на ближайшие 3 месяца

Модель TBATS

Дополнительно к данной выборке применим модель TBATS (Trigonometric seasonal components, Box-Cox transformation, ARMA errors, Trend and Seasonal components). Теоритическая часть представлена ниже.

Данный модель использует комбинацию из рядов Фурье, модель пространства состояний с экспоненциальным сглаживанием, а также преобразование Бокса - Кокса. Причём выбор параметров осуществляется полностью автоматизированным образом. Таким образом, модель TBATS позволяет моделировать постепенно меняющуюся сезонность, за счёт введения в модель комбинаций из рядов Фурье.

Пусть y_t -наблюдение в момент времени t .

Трансформация Боакса- Кокса, применяющаяся к y_t выглядит следующим образом:

$$y_t^{(\omega)} = \begin{cases} \frac{(y_t^\omega - 1)}{\omega}, & \omega \neq 0 \\ \log(y_t), & \omega = 0 \end{cases}$$

Наблюдения моделируются, как ряд:

$$y_t^{(\omega)} = l_{t-1} + \phi b_{t-1} + \sum_{i=1}^M s_{t-m_i}^{(i)} + d_t \quad (1)$$

где

$$b_t = (1 - \phi)b + \phi b_{t-1} + \beta d_t, \text{ отражает глобальный тренд} \quad (2)$$

$$l_t = l_{t-1} + \phi b_{t-1} + \alpha d_t, \text{ отражает локальный тренд} \quad (3)$$

$$d_t = \sum_{i=1}^p \phi_i d_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t, \text{ ошибки в форме ARMA} \quad (4)$$

В уравнении (1) имеем M сезонных периодов, каждый из которых, в свою очередь состоит из $s_t^{(i)} = \sum_{j=1}^{k_i} s_{j,t}^{(i)}$, каждое слагаемое тут моделируется при помощи ряда Фурье.

$$s_{j,t}^{(i)} = s_{j,t-1}^{(i)} \cos \lambda_j^{(i)} + s_{j,t-1}^{*(i)} \sin \lambda_j^{(i)} + \Gamma_1^{(i)} dt$$

$$s_{j,t}^{(i)} = -s_{j,t-1}^{(i)} \sin \lambda_j^{(i)} + s_{j,t-1}^{*(i)} \cos \lambda_j^{(i)} + \Gamma_2^{(i)} dt$$

Результаты моделирования

Для обучающей выборки было отложено 79% исходных данных (266 недель), остальные данные (67 недель) использовались для оценки качества прогноза. График полученного ряда представлен на рисунке 16.

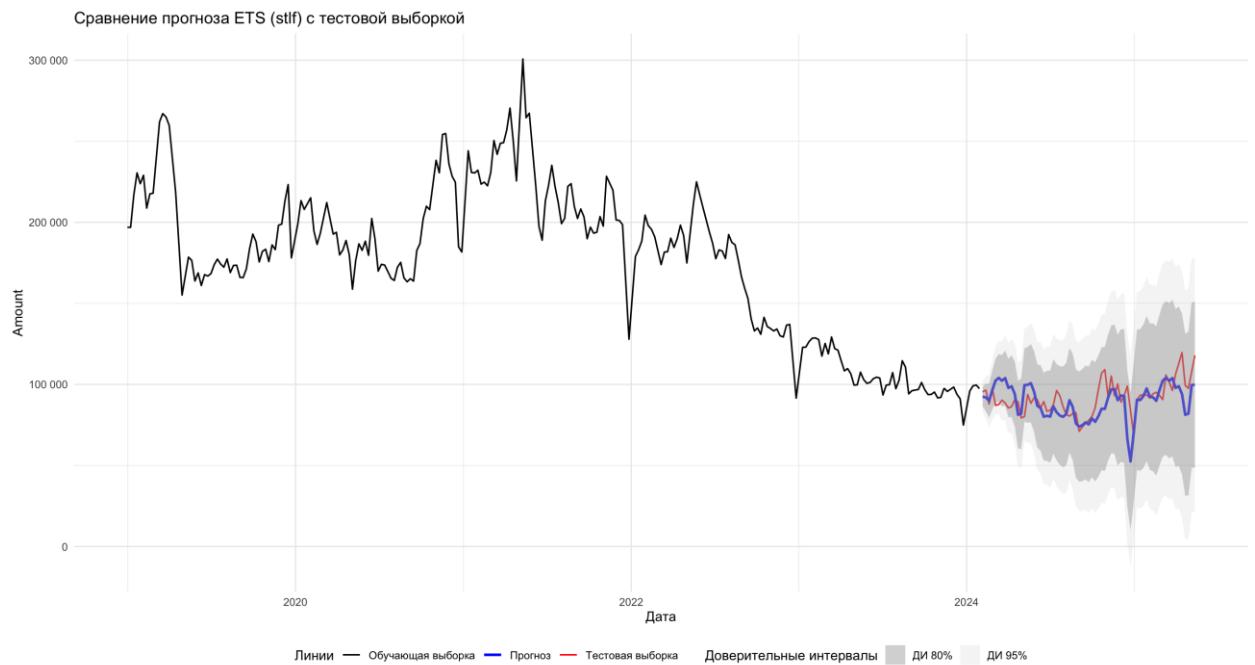


Рисунок 16 – График модели

Анализ остатков

По рисунку 17, на котором представлен график остатков для прогноза по модели и коррелограмма остатков, можно сделать вывод, что остатки модели в целом распределены симметрично относительно нуля, что указывает на несмещённость модели.

На коррелограмме все также видны отдельные пики, выходящие за границы доверительных интервалов, что может свидетельствовать о наличии остаточной автокорреляции.

Для подтверждения выводов проведены статистические тесты:

Таблица №6 – Тесты для остатков модели

Тест	Результаты
KPSS test	KPSS Level = 0.20818, Truncation lag parameter = 5, p-value = 0.1
Box-Ljung test	X-squared = 105.33, df = 52, p-value = 1.75e-05

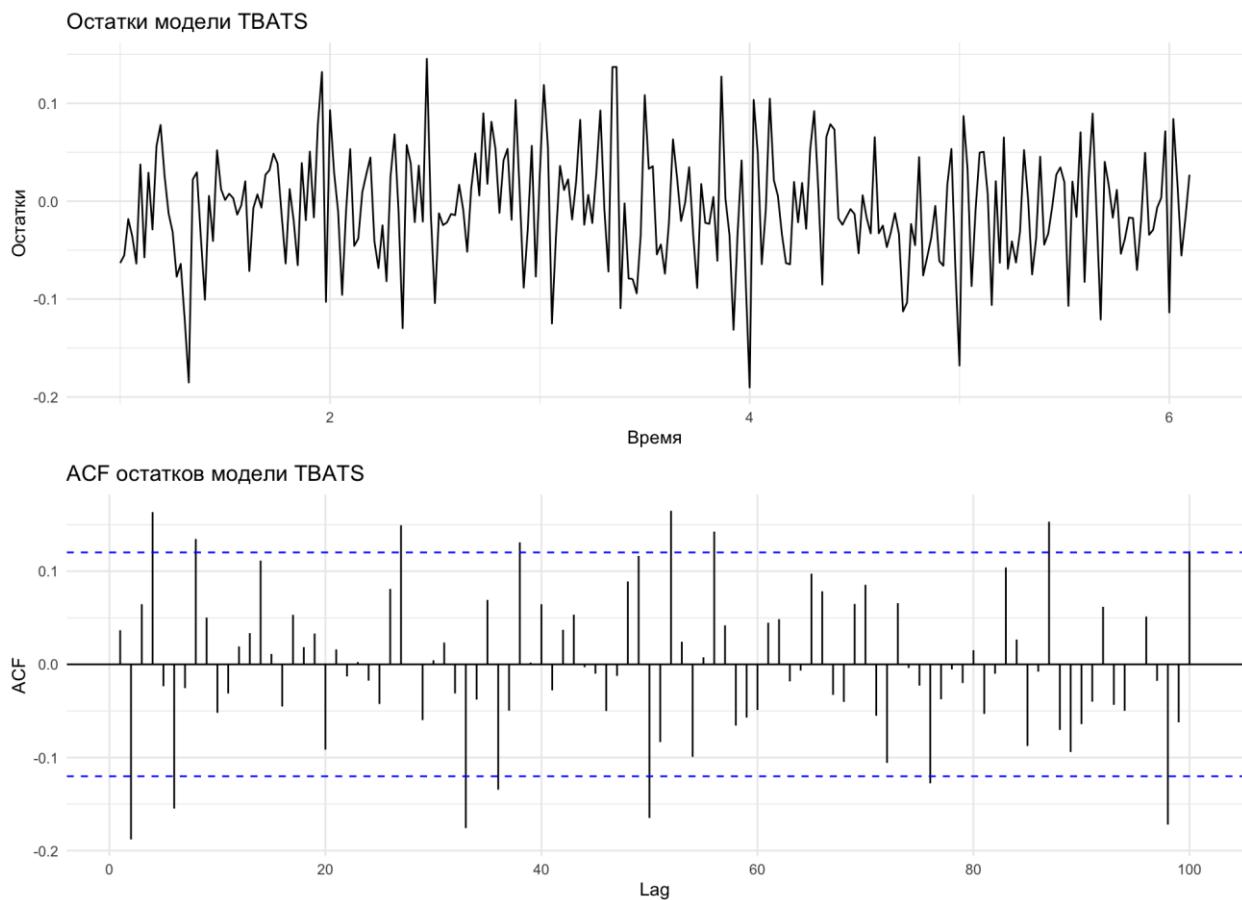


Рисунок 17 – График и кореллограмма остатков

Оценка качества прогноза

Модель обеспечивает качественный прогноз (MAPE = 8.64%, MAE = 7805.23, RMSE = 9574.9), однако остатки обладают автокорреляцией, что указывает на неполное объяснение внутренней структуры временного ряда.

Это ограничивает интерпретируемость модели, несмотря на хорошие метрики точности.

Спрогнозируем значения ряда на 3 месяца вперед по выбранной модели. Однако, учитывая автокоррелированность остатков, этот прогноз нельзя считать полностью адекватным. Результаты представлены на рисунке 18.

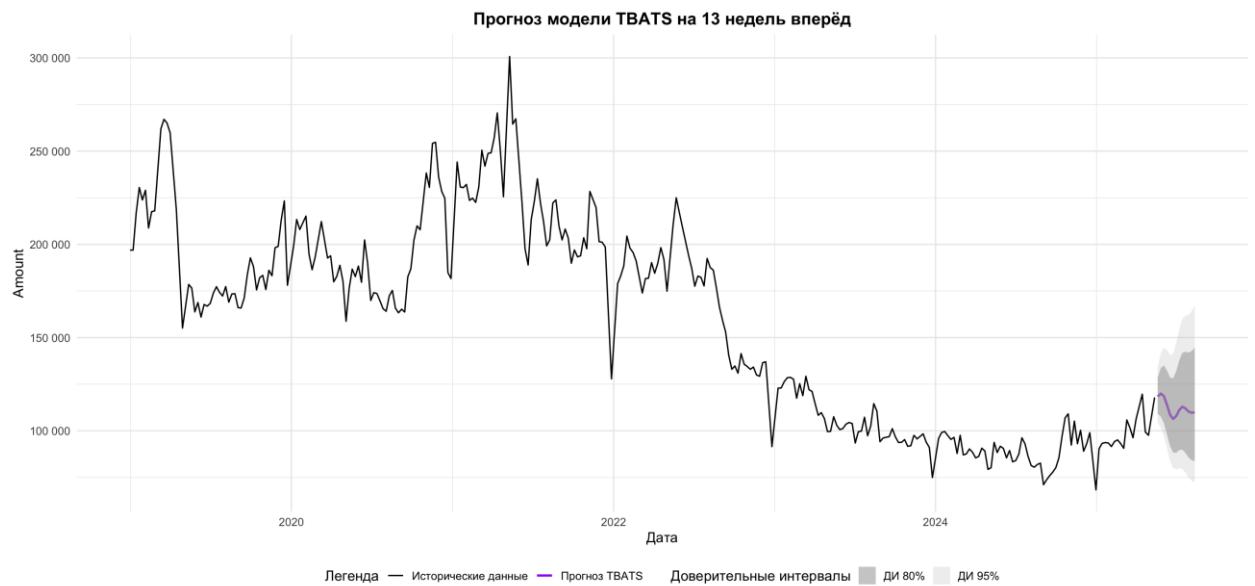


Рисунок 18 – График прогноза модели TBATS

Сравнительный анализ моделей

В результате проделанной работы можно сделать вывод, что SARIMA-модель в данном случае показала худшие результаты среди рассмотренных моделей. Хотя она достаточно проста в настройке и предоставляет гибкость при учёте сезонности и тренда, её качество прогноза оказалось неудовлетворительным: MAPE составил 24.29%, что значительно превышает допустимый порог в 10%. Это указывает на недостаточную точность и необходимость либо тонкой настройки, либо смены подхода.

Модель трёхпараметрического экспоненциального сглаживания показала более приемлемый результат с MAPE 8.78%, вписываясь в рамки «хорошей модели» по принятым критериям. Однако и здесь наблюдается автокорреляция остатков, что свидетельствует о наличии необработанных

паттернов в данных.

Наиболее высокую точность продемонстрировала модель TBATS, которая специально разрабатывалась для работы с комплексной сезонностью. Она достигла MAPE всего 8.64%, а также показала наименьшие значения MAE и RMSE среди всех трёх моделей. Тем не менее, и здесь остатки остаются автокоррелированными.

Таким образом, модель TBATS можно признать наиболее предпочтительной с точки зрения качества прогноза. В то же время, наличие автокорреляции в остатках всех моделей подчеркивает, что временной ряд содержит дополнительные зависимости или сезонные эффекты, которые ещё не были полностью учтены.

Таблица 7 – Сравнение метрик моделей

Модель	MAPE (%)	MAE	RMSE	Автокорреляция остатков
SARIMA(3,1,0)(0,1,0)	24.29	23 429	29 521	Есть
Модель Хольта-Уинтерса	8.78	8 160.39	11 178.78	Есть
TBATS	8.64	7805.23	9574.9	Есть

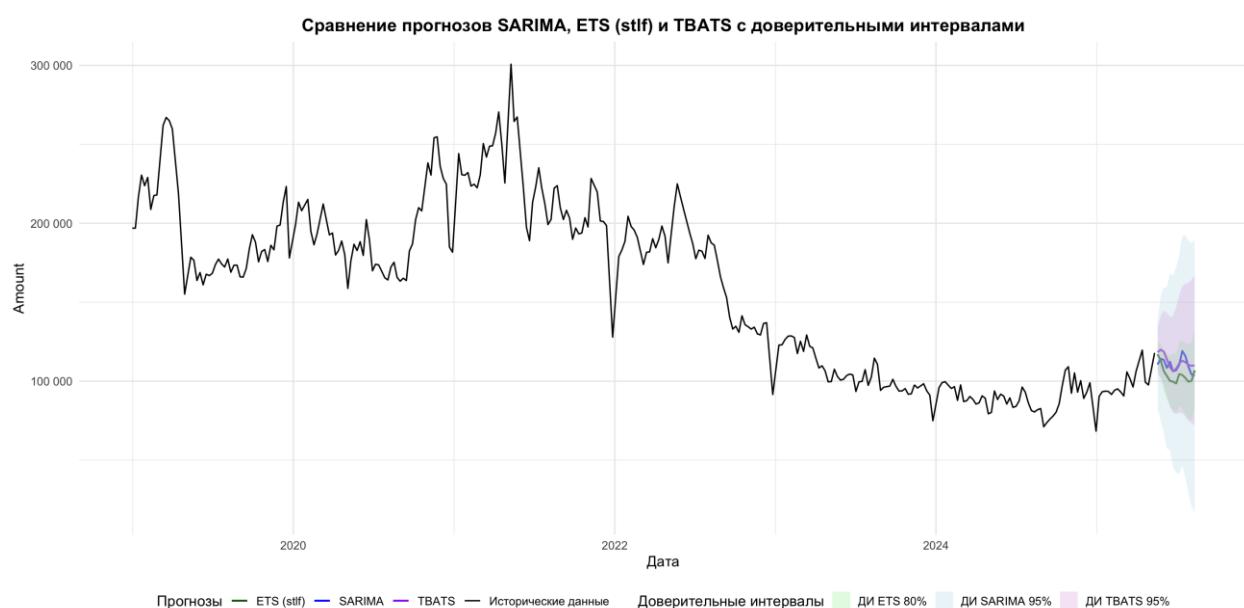


Рисунок 19 – Визуальное сравнение прогнозов моделей